



智能计算系统学习日志

从神经网络到全栈系统

作者: ZHY

时间: July 16, 2026

版本: 0.1



不要以为抹消过去，重新来过，即可发生什么改变。——比企谷八幡

目录

第 1 章 智能计算系统认知地图	1
1.1 人工智能及其计算系统发展脉络	1
1.2 智能计算系统框架	1
第 2 章 神经网络基础	2
2.1 机器学习经典框架	2
2.2 线性回归模型	3
2.2.1 Representation	3
2.2.2 Evaluation	3
2.2.3 Optimization	3
2.3 神经网络	4
2.3.1 Representation	4
2.3.2 Evaluation	5
2.3.3 Optimization	5
2.4 从线性到非线性：R-E-O 框架的延展	6

第 1 章 智能计算系统认知地图

内容提要

智能计算系统发展史

智能计算系统全流程视图

- 本课程本质上探讨一个问题：如何从无到有实现人工智能。
- 该问题源于一个关键预设：人工智能的实现是一个系统工程，今天大家却大部分仅关注算法问题。
- 新的时代对人工智能的需求勃发，新的系统被称为智能计算系统。
 - 智能的核心是算法，算法运行在具体的机器上，机器的运行代价不容忽视。
 - 想要在现实世界中设计优化并运用人工智能算法，必须了解整个智能计算系统。

1.1 人工智能及其计算系统发展脉络

纵观计算机发展百年史，每一代人工智能浪潮，总是经历着先是核心认知思路的改变，再到具体算法不断演进，配套的计算系统开始设计重组，最终人们的生活形成大的变化。

总结如下。

表 1.1: 三代智能计算系统对比

特征维度	第一代 (1980s)	第二代 (2010s)	第三代
核心认知	符号主义	连接主义	二者融合
方法论	形式逻辑、专家系统	深度学习、反向传播	探索中
计算载体	Prolog 机、LISP 机等专用计算机	GPU、AI 专用芯片 (TPU/NPU)	探索中
核心瓶颈	逻辑规则难以穷尽	算力与能耗瓶颈	探索中

1.2 智能计算系统框架

从系统层面观察一个大语言模型，其简要架构如下图所示。本课程核心目标就是打通智能系统全流程。




图 1.1: NPU 推理全栈流程图

第2章 神经网络基础

内容提要

- 线性回归模型
- 正则化思路

- 交叉验证方法
- 神经网络基础

本章内容看上去杂多，实则只是讨论了两个子问题。

- 以线性回归为例，讨论了机器学习的基本流程。
- 以神经网络为例，讨论了深度学习的基本流程。

二者同属一派，关系如下图所示。




图 2.1: 机器学习、深度学习与人工智能的关系

2.1 机器学习经典框架

所有的机器学习算法本质上都是在某一输入空间和输出空间中，寻找一个函数模型，其可以最好地描述输入数据和输出数据的关系。因此所有的机器学习算法必然由三部分组成。

- **Representation:** 选择一个函数模型，作为输入和输出的映射关系。
- **Evaluation:** 选择一个评价函数，作为衡量模型好坏的标准。
- **Optimization:** 选择一个优化算法，作为寻找最优模型的手段。

上述分析思路我们称之为 **R-E-O** 框架。接下来，我们将以此为线索讨论两个经典模型。

2.2 线性回归模型

2.2.1 Representation

命题 2.1 (线性回归模型的输入输出空间)

线性回归模型在下述空间中被定义。

输入: $\mathbf{x} = [1, x_1, \dots, x_m]^T \in \mathbb{R}^{m+1}$

输出: $y \in \mathbb{R}$

数据集: $\mathcal{S} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^n$

核心假设:

- 输入 $\mathbf{x}$ 是随机变量 $\mathcal{X}$ 的采样结果
- 输出 y 是随机变量 $\mathcal{Y}$ 的采样结果
- $(\mathbf{x}, y)$ 是联合分布 $\mathcal{D}$ 的采样结果
- 数据集 $\mathcal{S}$ 是联合分布 $\mathcal{D}^n$ 的独立同分布采样结果

定义 2.1 (线性回归模型)

线性回归模型在函数空间 $\mathcal{F}$ 中试图寻找一个线性映射 f_w

$$\mathcal{F} = \{f_{\mathbf{w}}(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} \mid \mathbf{w} = [w_0, w_1, \dots, w_m]^T \in \mathbb{R}^{m+1}\} \quad (2.1)$$

对于给定的 $\mathbf{w}$, 有 $f_{\mathbf{w}}(\mathbf{x}) = w_0 + w_1 x_1 + \dots + w_m x_m$ 。

注 上述论述是线性回归模型的形式化定义。一言以蔽之, 线性回归模型假设 $\mathbf{x}$ 和 y 之间的关系是线性的, 并且通过参数 $\mathbf{w}$ 来描述这种线性关系。

2.2.2 Evaluation

在线性回归中, 评估函数衡量模型预测值 $f_{\mathbf{w}}(\mathbf{x})$ 与真实值 y 之间的差距。最常用的选择是均方误差 (Mean Squared Error, MSE)。

定义 2.2 (线性回归的损失函数)

给定数据集 $\mathcal{S} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^n$, 线性回归模型的损失函数定义为:

$$\mathcal{L}(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \left(f_{\mathbf{w}}(\mathbf{x}^{(i)}) - y^{(i)} \right)^2 \quad (2.2)$$

等价地, 可以写成矩阵形式:

$$\mathcal{L}(\mathbf{w}) = \frac{1}{n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 \quad (2.3)$$

其中 $\mathbf{X} \in \mathbb{R}^{n \times (m+1)}$ 为设计矩阵, $\mathbf{y} = [y^{(1)}, \dots, y^{(n)}]^T$ 。

注 MSE 作为评估函数的合理性源于其数学性质: 在误差服从均值为零的高斯分布假设下, 最小化 MSE 等价于极大似然估计。这一性质为线性回归提供了概率论层面的解释。

2.2.3 Optimization

线性回归的优化目标是 minimize 损失函数 $\mathcal{L}(\mathbf{w})$, 即求解:

$$\mathbf{w}^* = \arg \min_{\mathbf{w}} \mathcal{L}(\mathbf{w}) \quad (2.4)$$

由于 $\mathcal{L}(\mathbf{w})$ 是凸函数, 存在闭式解 (解析解) 和数值解两种求解路径。

命题 2.2 (线性回归的闭式解)

令 $\nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}) = 0$ ，可得：

$$\mathbf{w}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \quad (2.5)$$

该解被称为普通最小二乘（**Ordinary Least Squares, OLS**）估计量。



注 闭式解的求解需要 $\mathbf{X}^T \mathbf{X}$ 可逆。当特征数 m 很大 ($m > n$) 或存在多重共线性时，矩阵不可逆，此时必须引入正则化项。

在实际应用中，由于矩阵求逆运算复杂度很高，通常采用**梯度下降（Gradient Descent）**进行迭代求解。

命题 2.3 (线性回归: 梯度下降法)

从几何直观上理解，梯度是函数上升最快的方向，因此沿着梯度的反方向更新参数 $\mathbf{w}$ ，可以逐步逼近最优解：

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}) \quad (2.6)$$

其中 η 为学习率，梯度计算公式为：

$$\nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}) = \frac{2}{n} \mathbf{X}^T (\mathbf{X} \mathbf{w} - \mathbf{y}) \quad (2.7)$$



注 从 R-E-O 框架审视线性回归：线性函数族完成了表示，MSE 完成了评估，而解析解或梯度下降完成了优化。三者合在一起，构成了一个有完整数学闭合形式的机器学习算法。

2.3 神经网络

如果说线性回归是最简单的机器学习模型，那么神经网络则代表了另一条截然不同的路线：通过组合基本非线性单元来逼近任意复杂函数。

2.3.1 Representation

定义 2.3 (人工神经元)

一个神经元是一个计算单元，接收输入向量 $\mathbf{x} \in \mathbb{R}^d$ ，输出标量值：

$$a = \sigma(\mathbf{w}^T \mathbf{x} + b) \quad (2.8)$$

其中 $\mathbf{w} \in \mathbb{R}^d$ 为权重向量， $b \in \mathbb{R}$ 为偏置， $\sigma(\cdot)$ 为激活函数（如 ReLU、Sigmoid、Tanh）。

**定义 2.4 (神经网络的前向传播)**

一个 L 层前馈神经网络通过逐层复合的方式定义函数：

$$f(\mathbf{x}) = f_L \circ f_{L-1} \circ \cdots \circ f_1(\mathbf{x}) \quad (2.9)$$

其中每一层 f_ℓ 是一个仿射变换 ($\mathbf{z}_\ell = \mathbf{W}_\ell \mathbf{a}_{\ell-1} + \mathbf{b}_\ell$) 后接激活函数 σ_ℓ 。

记第 ℓ 层的神经元数为 d_ℓ ，输入层 $d_0 = m$ ，输出层 $d_L = k$ 。则第 ℓ 层的参数矩阵为：

$$\mathbf{W}_\ell \in \mathbb{R}^{d_\ell \times d_{\ell-1}}, \quad \mathbf{b}_\ell \in \mathbb{R}^{d_\ell} \quad (2.10)$$

整个网络的参数集合为 $\theta = \{\mathbf{W}_\ell, \mathbf{b}_\ell\}_{\ell=1}^L$ 。



定理 2.1 (通用近似定理, Universal Approximation Theorem)

设 $\sigma(\cdot)$ 为一非常数、有界、单调递增的连续激活函数（如 Sigmoid 或 Tanh）。令 I_m 表示 m 维单位超立方体 $[0, 1]^m$, $C(I_m)$ 表示定义在 I_m 上的所有连续函数构成的空间。则对于任意目标函数 $f \in C(I_m)$ 和任意精度 $\varepsilon > 0$, 存在整数 N 、实数常数 $v_i, b_i \in \mathbb{R}$ 以及实向量 $\mathbf{w}_i \in \mathbb{R}^m$ ($i = 1, \dots, N$), 使得如下形式的单隐层前馈神经网络:

$$F(\mathbf{x}) = \sum_{i=1}^N v_i \sigma(\mathbf{w}_i^T \mathbf{x} + b_i) \quad (2.11)$$

可以作为 f 的近似函数, 满足:

$$|F(\mathbf{x}) - f(\mathbf{x})| < \varepsilon, \quad \forall \mathbf{x} \in I_m \quad (2.12)$$

注 该定理表明, **宽度** (即单层神经元数) 足够大的前馈神经网络具有万能逼近能力。它说明神经网络的表示能力在理论上是完备的——任何连续函数都可以用单隐层网络以任意精度逼近。但该定理具有以下重要局限:

1. **未保证学习效率**: 未说明达到给定精度所需的最小神经元数 N 。
2. **未保证可学习性**: 不保证梯度下降等优化算法能找到它。
3. **未保证泛化性**: 需要额外的正则化与验证。

表示、评估和优化三个环节各自的理论边界, 决定了实际系统的性能上限。即使表示能力极强也无济于事。

2.3.2 Evaluation

神经网络的评估函数取决于任务类型, 通常采用极大似然估计框架进行统一理解。

定义 2.5 (神经网络中的损失函数)

根据任务类型, 常见的损失函数有:

- 回归任务: 均方误差 (MSE), $\mathcal{L} = \frac{1}{n} \sum_{i=1}^n \|f(\mathbf{x}^{(i)}) - \mathbf{y}^{(i)}\|_2^2$
- 二分类任务: 二元交叉熵 (Binary Cross-Entropy), $\mathcal{L} = -\frac{1}{n} \sum_{i=1}^n [y^{(i)} \log \hat{y}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})]$
- 多分类任务: 交叉熵 (Cross-Entropy), $\mathcal{L} = -\frac{1}{n} \sum_{i=1}^n \sum_{j=1}^k y_j^{(i)} \log \hat{y}_j^{(i)}$

2.3.3 Optimization

不同于线性回归的凸优化问题, 神经网络的损失函数是高度非凸的, 不存在闭式解。优化依赖于**反向传播 (Backpropagation)** 和梯度下降及其变体。

定义 2.6 (反向传播算法)

对于第 ℓ 层的参数, 梯度通过链式法则从输出层向输入层逐层传递:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}_\ell} = \boldsymbol{\delta}_\ell \cdot \mathbf{a}_{\ell-1}^T \quad (2.13)$$

其中 $\boldsymbol{\delta}_\ell = \frac{\partial \mathcal{L}}{\partial \mathbf{z}_\ell}$ 为第 ℓ 层的误差项, $\mathbf{a}_{\ell-1}$ 为前一层激活值。

定义 2.7 (神经网络的参数更新)

采用随机梯度下降 (SGD) 或其自适应变体进行参数更新:

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \cdot \frac{1}{B} \sum_{i \in B} \nabla_{\boldsymbol{\theta}} \mathcal{L}^{(i)}(\boldsymbol{\theta}) \quad (2.14)$$

其中 B 为 mini-batch, $B = |B|$ 为批大小。

实际训练中常用更先进的优化器 (如 Adam、AdamW), 其核心是自适应调整每个参数的学习率。

命题 2.4 (神经网络优化的核心挑战)

神经网络的优化面临以下关键挑战：

- 非凸性：损失函数存在大量局部极小值和鞍点，梯度下降无法保证收敛到全局最优。
- 梯度消失/爆炸：在深层网络中，梯度逐层相乘可能导致数值不稳定，梯度消失使浅层无法更新，梯度爆炸导致训练发散。
- 过拟合：由于参数量巨大（大模型参数量可达千亿级别），神经网络极易过拟合，必须依赖正则化技术：

$$\mathcal{L}_{\text{reg}}(\theta) = \mathcal{L}(\theta) + \lambda \Omega(\theta) \quad (2.15)$$

其中 $\Omega(\theta)$ 为参数范数惩罚（L1/L2），Dropout、早停等同样为有效手段。



注 从 R-E-O 框架审视神经网络：网络的深度和宽度决定了 Representation，损失函数与评价指标共同构成 Evaluation，而反向传播 + 梯度下降则构成了 Optimization。

2.4 从线性到非线性：R-E-O 框架的延展

命题 2.5 (R-E-O 框架的统一视角)

线性回归和神经网络虽然是复杂度迥异的两个模型，但在 R-E-O 框架下呈现出统一的结构：

	Representation	Evaluation	Optimization
线性回归	线性函数 $\mathcal{F} = \{\mathbf{w}^T \mathbf{x}\}$	MSE	解析解 / 梯度下降
神经网络	非线性复合函数	交叉熵 / MSE	反向传播 + SGD/Adam

机器学习算法的演变本质上是这三部分各自独立演进与协同创新的历史：表示的复杂化（从线性到非线性）、评估任务的多元化（从回归到生成）、优化技术的精进。理解了三者之间的相互作用，就理解了机器学习的核心方法论——而这也正是《智能计算系统》课程的理论起点。

